

Агент как единица анализа

Слово «агент» обозначает здесь не человека с независимой волей, а программный участник, которому заданы роль, доступный контекст и действия. Это важно для интерпретации многоагентного результата. Несколько участников могут работать через одну модель и обмениваться её же предположениями; различие ролей не создаёт автоматически независимых знаний. Если команда получила неверный итог, нужно различить ошибку понимания задачи, потерю состояния и слабую проверку готового ответа. Анализ последовательности сообщений раскрывает некоторые из этих различий, которых не видно по одной финальной фразе.

MAST определяет агента через указания, состояние разговора и взаимодействие со средой; многоагентная система координирует несколько таких участников. Работа изучает траектории выполнения, а не только финальные ответы.

Поведение зависит от конкретной оркестрации и моделей. Наблюдение на опубликованных системах не измеряет все возможные команды.

Где возникает сбой между заданием и результатом? Трасса позволяет увидеть место передачи и пропущенной проверки. Обозначение «агент» полезно лишь вместе с описанием наблюдаемых действий. Иначе человеческая метафора незаметно заменяет анализ программного процесса.

Сходные роли могут взаимодействовать по разным правилам. Одна команда передаёт все сообщения всем, другая ограничивает обмен; одна принимает результат после голосования, другая зависит от последнего исполнителя. Поэтому название должности в промпте почти ничего не сообщает о фактическом информационном пути. Именно путь следует иметь в виду, когда интерпретируют успех или провал.

От исходных трасс к таксономии

Таксономия возникает из чтения случаев, а не падает из определения модели. Исследователи обсуждают повторяющиеся виды сбоев и закрепляют их в категориях, которыми затем можно размечать новые траектории. Это создаёт общий язык, но границы категорий остаются аналитическим выбором. Например, пропущенный контроль мог быть следствием неверно заданной роли и недостатка информации между участниками. При подсчёте важно понимать, допускает ли разметка несколько меток и какую задачу вообще признали неудачной. Число видов отказа не говорит, что иных видов в будущем быть не может.

В MAST исходный качественный анализ более 150 трасс послужил основанием для 14 видов отказов в трёх группах. Авторы привлекали экспертных аннотаторов и отдельно масштабировали разметку.

Таксономия выросла из выбранных систем и не претендует на полноту будущих ошибок. Качественная основа и большой массив размечались не одинаково.

Как читать число категорий? Это рабочее описание наблюдавшихся случаев, а не природная константа. Новая категория может понадобиться для будущих систем. Это нормальная граница эмпирической таксономии, построенной на конечном множестве трасс.

Отдельный эпизод способен содержать несколько правдоподобных причин. Если неверный ответ одновременно связан с потерей контекста и отсутствием финальной проверки, классификатору надо определить смысл обеих меток. Публичная таксономия делает возможным обсуждение таких разногласий, но не превращает пограничные случаи в однозначные факты природы.

Масштаб и источник разметки

Большой массив трасс производит впечатление точности, однако метки большой коллекции зависят от процесса их получения. Экспертная разработка категорий и автоматизированное распространение меток - разные этапы доказательства. Высокое согласие с людьми на проверенном наборе укрепляет доверие к способу аннотации, но не доказывает правильность каждой записи или перенос на другую архитектуру. Особенно важно не цитировать старую аннотацию препринта, когда актуальная версия изменила число систем и объём данных. Дата версии относится к содержанию научного утверждения, а не только к оформлению библиографии.

Актуальная версия MAST описывает 1642 аннотированные трассы семи многоагентных систем; для масштабной аннотации применялся LLM-судья, сверяемый с экспертной разметкой.

Аннотация не является независимым повторным выполнением задач. Согласие оценщиков не удостоверяет безошибочность их общей интерпретации.

Что означает частота отказа? Она относится к данным и правилам данной разметки. Следовательно, 1642 записи расширяют охват наблюдения, но не делают каждую метку ручным экспертным заключением. Происхождение разметки обязательно для интерпретации.

Число экспертных трасс, из которых выработаны названия отказов, не следует смешивать с числом всех аннотированных трасс. Первые поддерживают содержательные определения категорий, вторые - распределение меток по исследованному массиву. Это два вывода с разной процедурой получения и разными ограничениями переноса.

Проектирование системы

Предположим, модель способна решить задачу, но инструкция роли запрещает ей обратиться к найденному документу или требует закончить раньше проверки. Конечный провал тогда нельзя объяснить только нехваткой предметного знания. Проектирование системы включает распределение обязанностей, память разговора и признаки завершения. В реальном случае эти компоненты взаимодействуют: неудачная формулировка задания может усиливать слабость модели. Анализ конкретных трасс показывает разнообразие подобных ситуаций, хотя одно наблюдение не позволяет точно разделить вклад каждого фактора. Потому классификацию следует читать как объясняющий инструмент, а не полную причинную декомпозицию.

Одна крупная группа MAST относится к постановке роли, условиям завершения и сохранению состояния. Сбой может возникнуть до предметного рассуждения агента.

Промпт и координация взаимодействуют с моделью; единичный случай не выделяет вклад каждой причины.

Можно ли приписать промах знаниям модели? Иногда проблема состоит в том, какую работу ей поручили и когда остановили. Когда провал возникает в правилах организации, замена модели не обязательно исправит его. Это не универсальное утверждение, а возможное объяснение конкретного случая.

Можно вообразить полностью точный предметный ответ, который никто в команде не доставил в окончательный файл из-за потерянного сообщения. В таком случае низкий балл системы совместим с достаточными знаниями некоторого участника. Это иллюстрация различия между способностью компонента и свойством совместного процесса, а не новый измеренный кейс.

Несогласование между участниками

Когда одна реплика передаёт другому агенту результат поиска, она несёт и явное содержание, и неявное указание о степени уверенности. Если второй участник принимает непроверенный фрагмент как установленный факт, ошибка разрастается в итоговом синтезе. Если возражение первого вообще не попало к финальному автору, число специалистов на схеме не отражает фактического использования их труда. Трасса общения позволяет увидеть такое расхождение. Но наблюдать текст сообщений - не то же самое, что знать внутреннюю причину их выбора. Следует удерживать различие между поведением и недоступным намерением.

Вторую группу MAST составляют ошибки согласования: сообщение игнорируется, участник не просит уточнения или теряет контекст общей задачи. Финальный текст может выглядеть цельным после такого разрыва.

Трасса фиксирует наблюдаемые сообщения, но не все внутренние мотивы модели. Категории способны пересекаться в одном эпизоде.

Достаточно ли присутствия эксперта в команде? Его свидетельство должно попасть в итоговую аргументацию. Передача сообщения тоже может потерять оговорку о сомнительности источника. Итоговый агент унаследует содержание и ошибочно повысит его статус.

Координация особенно важна, когда один участник располагает оговоркой, а другой пишет заключение. Потеря краткого слова «возможно» может превратить допустимую интерпретацию в категорическое утверждение. Итоговая ошибка тогда является содержательной, но появилась на информационной границе между частями работы.

Проверка и остановка

Последняя стадия выглядит простой: проверить ответ и остановиться. Но именно здесь разные представления об успехе могут разойтись. Исполнитель считает задачу завершённой после заполнения шаблона; заказчик ожидал подтверждения спорного факта первичной статьёй. Формальный тест отмечает корректный файл, хотя содержательный вывод ошибочен. Таксономия агентных отказов показывает, что контроль и завершение сами являются предметом исследования. Она не предоставляет универсальной процедуры научной рецензии. Понимание этого ограничения важно, чтобы не приравнять наличие роли «верификатор» к независимой проверке.

Третья группа MAST касается проверки задачи и завершения. Команда может остановиться преждевременно, не проверить полученный ответ или принять неправильный контрольный результат.

Тот же внешний признак успеха может скрыть дефект эталона; классификация не решает все вопросы о качестве контрольной задачи.

Что проверялось перед окончанием? Название роли «проверяющий» не гарантирует фактического чтения основания. Финальная проверка должна соответствовать цели задачи; проверка заполненности файла и проверка истинности исследования дают разный результат.

Иногда команда прекращает работу после первого видимого успеха, хотя ещё остаются противоречащие документы. В других случаях она продолжает бессмысленно повторять одни действия. Обе ситуации относятся к правилам завершения, однако требуют разных объяснений. Одно отрицательное число успеха не показывает, какая именно динамика наблюдалась.

Интервенционные кейсы

Локальное изменение организации команды способно улучшить измеренную задачу: например, окончательное решение принимает другой участник или уточняются обязанности проверки. Но такое изменение может помочь потому, что исправляет именно распространённый сбой выбранной системы. Перенос на иной набор задач не следует из кейса без новых данных. Положительный результат кейса и ограниченность его области совместимы. Особенно осторожным надо быть, когда меняются одновременно роли, модель и правила тестирования: тогда численная разница не является оценкой одного абстрактного свойства «агентности».

Авторы MAST приводят исследовательские кейсы изменений в организации двух систем и отмечают улучшения некоторых измеренных результатов. Их собственный анализ считает простые правки недостаточными для общей надёжности.

Локальное улучшение нельзя переносить на всякий агентный продукт; сравнение относится к выбранным задачам и конфигурациям.

Что доказывает кейс? В определённой среде структура системы может иметь наблюдаемое значение. Один успешный кейс не заменяет сравнительной оценки разнообразных условий. Он показывает, почему устройство команды заслуживает изучения.

Интервенционный пример ценен тем, что связывает классификацию отказа с измеренным изменением поведения конкретной системы. Он не устанавливает причинный закон для всех команд. Даже похожий ярлык отказа может скрывать иной контекст и иной способ взаимодействия. Читателю нужно удерживать зависимость результата от устройства кейса.

Спор как форма общения

Дебаты можно представить как сеть каналов, а не бесконечный общий чат. Плотная сеть позволяет быстро услышать каждый довод, но вызывает многократное повторение схожего содержания. Разреженная сеть уменьшает число сообщений и меняет порядок распространения идеи. Исследование топологии проверяет именно этот аспект при собственных моделях и задачах. Оно не устанавливает, что молчание всегда полезно: изоляция способна скрыть критическое возражение. Интересный вывод более ограничен - число коммуникационных связей является реальным фактором качества и расхода, а максимальное соединение не является очевидной нормой.

Исследование разреженной коммуникации сравнивает топологии дебатов нескольких агентов. В проверенных задачах уменьшение связей давало сопоставимые или лучшие показатели и снижало расход входных токенов.

Эксперименты касаются выбранных моделей и задач; токены не охватывают всю стоимость исследовательской работы.

Нужно ли каждому слышать каждого? Публикация показывает, что плотность связи является экспериментальной переменной. Сравнимая стоимость в статье имеет точное определение. При расширении на иную работу её состав может измениться радикально.

Если задача требует мгновенного ответа, экономия сообщений может быть существенной. Если задача требует многодневной проверки источников, процент входных токенов составляет лишь один компонент ресурсов. Те же эмпирические результаты остаются верными в своей таблице, но их практический смысл меняется вместе с определением полной стоимости.

Независимость и заражение ошибки

Если все участники обсуждения читают один неверный источник, их согласие будет сильным лишь внешне. В другой ситуации ограниченное общение может сохранить независимость первоначальных решений, но оставить одного агента без нужного уточнения. Оба механизма мыслимы, и их соотношение зависит от задания. Работы о топологии и о сбоях координации помогают назвать противоположные стороны обмена информацией; они не дают универсального оптимума для любой науки. Оценивать следует происхождение аргументов, возможность обнаружить несогласие и качество финальной проверки, а не красивую стенограмму спора.

Общение может передавать полезное возражение, но может распространять неверную предпосылку. Много реплик не означают множество независимых источников знания.

Работа о топологии измеряет показатели дебатов, а не полную причинную историю каждой ошибки.

Как интерпретировать согласие? Его сила зависит от происхождения аргументов и формы обмена. Согласие после обмена репликами нельзя считать независимым повторением. Общий канал способен одновременно повысить осведомлённость и распространить заблуждение.

Одна сеть может быстрее распространять верный контраргумент, другая сохранять разнообразие предположений. Оптимум этих качеств не задан термином «редкая» или «полная» связь. Исследование ограниченных топологий ценно тем, что переводит словесную интуицию об общении в сравниваемое свойство систем.

Сравнение с простым базисом

Больше участников обычно означает дополнительные вызовы модели, сообщения и возможность диагностировать сбой. Но прирост доли успеха имеет смысл только по отношению к альтернативе с сопоставимым бюджетом. Возможно, несколько независимых попыток одного исполнителя дали бы тот же эффект; возможно, специальная роль добавила принципиально иной контроль. Публикации на отдельных бенчмарках исследуют части этого сравнения. Из слова «многоагентный» нельзя вывести преимущество над одиночным исполнителем без постановки альтернативы, определения стоимости и одинакового критерия успеха.

Сложную команду следует понимать относительно альтернативы на том же задании. MAST мотивирован тем, что выигрыш многоагентных систем не всегда велик против простых базовых вариантов.

Не всякий базис имеет одинаковый вычислительный бюджет, а качество отдельных задач различается.

За что заплачена дополнительная сложность? Итоговая доля успеха без условий сравнения не отвечает. Без простого базиса неясно, что добавила координация сверх дополнительного числа попыток. Этот вопрос относится к причинной интерпретации преимущества.

Успех простого базиса тоже не обязательно означает, что команда бесполезна во всех задачах. Он показывает, что конкретное преимущество в конкретном сравнении не было установлено. Другие задачи могут по-иному зависеть от разделения труда. Отрицательный и положительный вывод одинаково нуждаются в указании набора условий.

Трасса и конечная метрика

Итоговый балл полезен для обзорной таблицы, но плохо показывает, когда в длинной цепочке возникла ошибка. Трасса добавляет последовательность запросов, ответов и переходов между участниками. Она может обнаружить, что важный документ был найден и затем проигнорирован, либо что неверный вывод появился ещё до поиска. При этом чтение трассы само требует классификации и может стать источником новых ошибок оценщика. Прозрачность материала предоставляет возможность оспорить интерпретацию, а не автоматически делает её правильной.

HELM подчёркивает прозрачность запросов и ответов в оценке моделей; MAST читает последовательные агентные трассы. Одно число успеха и запись процесса дают разные сведения.

Открытый след не делает слабый эталон сильным, а длинная трасса требует интерпретации.

Где видно причинное место ошибки? Последовательность действий помогает объяснить сбой, если классификация обоснована. Трасса раскрывает видимые переходы, однако невидимое знание модели не извлекается из неё напрямую. Объяснение всегда привязано к наблюдаемой записи.

В длинной трассе ошибка может иметь раннюю причину и позднее проявление. Первый агент пропустил документ, третий сделал недоказанный вывод, последний ответил уверенно. Классификация по месту видимого провала и классификация по предполагаемой первоначальной причине могут расходиться. Это ограничивает слишком прямолинейное чтение аннотированной последовательности.

Агент в программной задаче

Программное исправление удобно тем, что его можно запустить. Однако программный тест наблюдает лишь выбранные входы, а намерение задания может включать совместимость, исключения и побочные эффекты. Патч, прошедший имеющиеся проверки, иногда нарушает то, ради чего запрос был создан. Это делает аудит бенчмарка содержательно важным для оценки агента: ошибка может лежать как в действии исполнителя, так и в определении успешности. Из проверки одной комбинации агента и набора нельзя заключить общую долю неверных исправлений во всём программировании.

SWE-Bench+ аудирует оценку исправлений кода и показывает, что прохождение предусмотренных тестов может расходиться с содержательным успехом патча.

Конкретный аудит не даёт общей частоты сбоя всех кодовых агентов.

Что означает `resolved`? Значение зависит от тестов, среды и смысла задания. Исполняемость кода делает тест сильным свидетельством о проверенных входах. За пределами этих входов его доказательная сила ограничена.

Тестовые случаи могли быть выбраны до появления патча и не включать крайний вход, который новая реализация нарушает. Прохождение прежнего набора сообщает истинное свидетельство о данных случаях, но не делает новую реализацию эквивалентной ожидаемому поведению во всей области входов. Этот логический предел полезен и вне программирования.

Судья результатов

Масштабный анализ трасс практически нуждается в помощнике для классификации, но модельный судья может сам зависеть от формы предъявления. Статья о позиционном смещении измеряет эту зависимость в парных оценках; она не является прямым пересчётом агентного набора MAST. Её значение здесь методологическое: автоматизация оценки требует знать свойства оценщика. Экспертная проверка части данных, согласие меток и устойчивость к изменению запроса отвечают на разные вопросы. Отсутствие идеального судьи не делает масштабную разметку бесполезной, но ограничивает силу её чисел.

MAST масштабировал аннотацию с модельным оценщиком; отдельное исследование судей обнаружило позиционную предвзятость в сравнении ответов. Это разные применения судьи.

Позиционный эффект не является прямой оценкой MAST-аннотатора; его величину нельзя подставлять в чужую таблицу.

Кто измеряет измерителя? Согласие с экспертами и устойчивость к представлению являются отдельными вопросами. Нельзя переносить размер смещения одного исследования судей на другое применение. Нужна собственная проверка соответствующей процедуры разметки.

Согласие модельного оценщика с людьми на отобранном наборе показывает сопоставимость там, где проводилось сравнение. Систематическая ошибка за пределами этого набора может остаться незамеченной. Поэтому большую размеченную коллекцию разумно читать как результат оценочной процедуры, а не как непосредственную запись причин отказа без посредника.

Свойства бенчмарка

Широкая сравнительная таблица делает видимыми качества, которые одна точность скрывает: устойчивость, калибровку, эффективность и иные свойства. Но даже много показателей могут опираться на слабую отдельную задачу. В коде недостаточный тест способен неверно объявить патч успешным, независимо от того, сколько других метрик включено в отчёт. В обратную сторону глубокий аудит одного задания не сообщает широты поведения модели на иных сценариях. Две формы критики оценки дополняют друг друга концептуально: охват и валидность конкретного эталона нуждаются в отдельном рассмотрении.

HELM сопоставляет разные сценарии и метрики, тогда как SWE-Bench+ разбирает недостатки контрольных заданий в программировании. Вместе они показывают две стороны оценки: широкий охват и качество локального эталона.

Широкий список метрик не исправляет конкретный неверный тест, а аудит одного теста не охватывает все риски.

Какие свойства действительно наблюдаемы? Ответ определяется устройством набора и выбранным уровнем анализа. Охват и валидность различаются: широкий список заданий способен скрывать локальные дефекты, а глубокий аудит одного задания не обеспечивает широту.

Качество оценки определяется также тем, что считается задачей. Один бенчмарк требует получить численный ответ, другой - исправить программу без побочного дефекта. Различные требования не складываются в одну ось сложности. Много показателей полезны тогда, когда пользователь может понять, какое требование соответствует его вопросу.

Задача и её суррогат

У агента есть практическая цель, а у бенчмарка - наблюдаемый её заместитель. Заместитель нужен, поскольку нельзя непосредственно измерить каждое будущее последствие программного изменения или научного текста. Разрыв между ними создаёт пространство для ложного успеха. Не обязательно предполагать намеренное «обманивание» модели: она может просто оптимизировать то, что доступно в контексте. Аудит задач обнаруживает реальные случаи расхождения. При переносе выводов следует назвать, какое свойство проверял тест и какие свойства требование оставило за его пределами.

Агент оптимизирует доступный признак завершения. Если проверка ограничена, он может получить положительную метку, не выполнив более широкое намерение пользователя.

Описанный механизм аналитически возможен; опубликованные аудиты измеряют лишь свои задачи и случаи.

Чем различаются цель и критерий? Суррогат нужно читать как частичное свидетельство, даже если он автоматизирован. Ярлык успеха должен сообщать объект измерения, а не обещать все свойства результата. Это особенно важно при автоматическом ранжировании систем.

Суррогат может пропускать не только ошибку результата, но и ошибку обоснования. Научное предложение с настоящей ссылкой способно приписать статье вывод, которого та не делает. Формальный признак наличия адреса выполнен, а исследовательская цель нарушена. Это параллель к слабому тесту кода, не прямой результат программной статьи.

Время и версии систем

Таблица из одной версии статьи может устареть после дополнения корпуса и уточнения метода. Актуальная MAST v3 содержит больше систем и трасс, чем ранние описания препринта. Аналогично программный тест и модельный API меняются, иногда без очевидного следа в кратком пересказе. Число успеха поэтому связано с временным снимком: определёнными инструкциями, окружением и изданием публикации. Проверка версии не является косметической библиографией. Она сохраняет предмет разговора и препятствует тому, чтобы старое измерение выдавали за результат нового состояния системы.

Многоагентная система включает модель, её инструкции, инструменты и тестовое окружение; изменение одного элемента меняет объект сравнения. Версия MAST v3 сама отличается от раннего описания числа систем.

Позднее обновление статьи не означает автоматической репликации старого эксперимента на новых моделях.

Как фиксировать предмет вывода? Дата и версия являются частью интерпретации опубликованного результата. Старое число, процитированное без версии, может быть точным для своего времени и неверным для актуальной публикации. Обе части сообщения существенны.

Смена версии затрагивает не только численность корпуса. Появление новых систем может изменить частоты меток и характер известных отказов. Поэтому следует ссылаться на актуальное содержание и не переносить автоматически ранний процент в обновлённое описание. История публикации является частью научной точности.

Ограничения лабораторной роли

Открытое исследование может требовать согласования неоднозначных свидетельств, тогда как бенчмарк предлагает однозначный ярлык ответа. В таком переносе меняется не только трудность задания, но и критерий того, что считать завершённой проверкой. Математический агент способен правильно назвать число и не нуждаться в атрибуции источника; исследовательский текст нуждается именно в ней. Многоагентные статьи демонстрируют поведение на своих тестах. Чтобы говорить о другой области, надо установить, какие из измеренных механизмов сохраняются при смене цели и эталона.

В математических и программных заданиях финальный результат часто легче формализовать, чем открытый исследовательский вывод. Работы о системах агентов изучают свои условия контроля.

Наблюдения не устанавливают качество научной аргументации в областях без однозначного ответа.

Как далеко переносить вывод? Нужно отдельно рассмотреть различия эталона, документов и ответственности за интерпретацию. Перенос в научный обзор требует проверять источники, оговорки и спорные интерпретации. Эти свойства не представлены автоматически в задачах вычисления ответа.

Текстовый обзор также может не иметь единственного эталонного решения: разные школы интерпретации расходятся при одинаковых источниках. Это затрудняет перенос автоматической метки успешности из задач с числом или программным тестом. Содержательная проверка должна различать факт источника, качество аргумента и право на осторожный вывод.

Неудача как источник знания

Неудачный случай сообщает о возможности определённого сбоя, а большой размеченный массив помогает оценить его распространение в выбранной среде. Эти два вывода отличаются. Ручной аудит патчей способен показать, что успешный тест не всегда означает исправление; он не измеряет каждый репозиторий. Таксономия агентных трасс способна выявить повторяемый вид провала; она не гарантирует одинаковую частоту в новой системе. При чтении полезно сначала назвать механизм, затем отдельно спросить, насколько часто он наблюдался и по какой процедуре подсчёта.

Аудит ошибок даёт информацию, скрытую средним процентом успеха. Таксономия трасс объясняет виды сбоев, а ручная проверка патчей выявляет слабость контрольной метки.

Оба подхода зависят от выбранных случаев и компетенции аннотаторов; отдельный эпизод не определяет базовую частоту.

Что именно обобщается? Механизм неудачи и его распространённость являются разными утверждениями. Механизм, найденный в одном аудите, полезен для постановки вопросов. Его долю на иной популяции нельзя получить простым пересчётом.

Таксономия помогает увидеть тип отказа даже тогда, когда его встречаемость неизвестна в новом месте. Аудит теста помогает сомневаться в ярлыке успеха даже при хорошем среднем проценте. Эти достоинства не требуют преувеличить репрезентативность отдельных публикаций. Они работают как конкретные свидетельства о возможных механизмах.

Неразрешённые сравнения

Сравнивать организацию команды трудно, когда одновременно меняются модель, число попыток и правила обмена. Положительное наблюдение от разреженного спора не означает, что он выиграет при иной цели. А классификация MAST помогает объяснить сбои, но сама по себе не измеряет выигрыш конкретной будущей архитектуры. Неполный тест кода добавляет неопределённость в сам исход сравнения. Эти ограничения оставляют открытым вопрос о том, когда дополнительная координация окупает собственную сложность. Отвечать на него следует только в рамках явно описанных опубликованных условий.

Остаётся открытым, когда дополнительное общение помогает больше, чем независимые попытки, и как проверять финальный результат при слабом эталоне. Публикации дают отдельные сопоставления.

Данные разных моделей и задач нельзя складывать в единую функцию цены и точности.

Какой результат изменил бы вывод? Сравнение должно говорить о конкретном свойстве, а не общей магии команды. Отсутствие универсального сравнения не отменяет частных результатов. Оно запрещает лишь выдавать разнородные наблюдения за один доказанный порядок систем.

Остаётся важным сравнение качества одной хорошо проверенной попытки с группой быстрых, но поверхностно согласованных попыток. Нынешние публикации не разрешают такой вопрос для всех исследовательских задач. Его постановка показывает, почему число агентов и число сообщений не являются достаточными признаками качества.

Предел опубликованного

Читатель может вынести из литературы не готовую организационную схему, а точное понимание силы свидетельства. Трассы говорят о наблюдаемых последовательностях и вариантах отказа; дебаты показывают влияние коммуникационной топологии в исследованных задачах; широкая оценка раскрывает компромиссы метрик. Всё это ограничено конкретными системами, задачами и способами разметки. Если финальный исследовательский вывод не подтверждён первичными документами, число агентов не восполнит пробел. Если тест слаб, высокий процент успеха также не удостоверит выполненную задачу. Это граница, которую стоит сохранить в общем выводе.

MAST показывает разнообразие наблюдавшихся отказов; работа о разреженных дебатах - роль топологии общения; HELM - необходимость нескольких метрик и прозрачного следа.

Ни одна из этих работ не доказывает универсальную надёжность автоматической исследовательской организации.

Что остаётся читателю? Уточнять единицу анализа, контрольную цель и источник каждого числа. Хороший итог обзора называет не только опубликованный эффект, но и то, что он не измерял. Именно это сохраняет возможность дальнейшей проверки.

Ни одно из измерений не освобождает финальное утверждение от связи с предметным источником. Даже идеально организованная команда может ошибиться, если все участники читают один неверный документ или неверно переносят его вывод на другой случай. Это самостоятельная граница агентной оценки, видимая лишь при чтении содержания ответа.