

Доказательство и цитата

Утверждение и источник

Научное предложение связывает объект, утверждаемое свойство и степень уверенности. Документ может подтверждать только один из этих элементов. Например, опубликованная оценка относится к конкретному набору вопросов, тогда как пересказ незаметно расширяет её на все области знания. Вопрос «есть ли ссылка?» при этом слабее вопроса «что ровно подтверждено?». Содержательная проверка начинается с грамматической структуры фразы: кто изучался, в каком режиме, какой результат наблюдался и какие условия ограничивали вывод. Эта аналитическая декомпозиция не является новым экспериментом; она объясняет, почему одна кликабельная ссылка может не спасти сложное предложение.

ALCE связывает текст ответа с предоставленными документами, а аудит генеративного поиска спрашивает, поддерживает ли конкретная ссылка соседнее утверждение. Разница между наличием URL и доказательной опорой фундаментальна: документ может быть настоящим и при этом говорить о другом.

Отношение поддержки иногда зависит от контекста, оговорок и терминов статьи. Автоматическая проверка такой связи сама допускает ошибку.

Какой участок источника действительно подтверждает предложение? В длинном ответе нужно оценивать отношения между каждым существенным тезисом и данными, а не только список литературы. Если фраза объединяет два исследования, стоит отдельно понять вклад каждого. Составная ссылка не делает автоматически подтверждённой связку между разными результатами.

Полнота цитирования

Полнота цитирования касается всех существенных утверждений ответа. Если три предложения из четырёх снабжены хорошими ссылками, четвёртое может содержать главный вывод и остаться неподтверждённым. Простое число ссылок на страницу ничего не говорит о том, какие части текста они покрывают. Для читателя особенно важны числа, сравнения, причинные связи и утверждения об отсутствии эффекта. Они могут опираться на разные источники, даже когда находятся в одном абзаце. Оценка полноты требует сначала увидеть сами утверждения, а затем проверить доступность соответствующего доказательства для каждого.

Авторы аудита называют полнотой ситуацию, когда каждое проверяемое утверждение имеет достаточную опору в ссылках. В исследованных поисковых системах этот критерий не следовал просто из наличия цитат. Несколько предложений рядом с одним маркером требуют отдельного чтения.

Полнота не равна правильности всего ответа: источник может поддерживать нерелевантный для вопроса факт. Кроме того, понятие проверяемой единицы меняется при делении сложного абзаца.

Какие части фразы остаются без опоры? Именно этот вопрос открывает невидимые иначе пробелы в кажущемся документированном тексте. Отсутствие ссылки на решающий тезис обычно важнее наличия десятка ссылок на вводные детали. Счёт адресов не заменяет счёт неподдержанных утверждений.

Точность цитирования

Точность цитирования спрашивает, поддерживает ли приведённый документ именно соседнее утверждение. Настоящая статья может говорить о корреляции в ограниченной выборке, а подпись к ней - объявлять универсальный причинный закон. Совпадение темы здесь недостаточно. Есть и более тонкий случай: источник подтверждает первую половину предложения, но ничего не говорит о второй. Ссылка выглядит уместной при быстром просмотре и всё же вводит в заблуждение. Поэтому точность оценивается на уровне связи содержания, а не только существования URL, фамилии автора или похожих ключевых слов.

Точность цитаты означает, что отмеченный документ действительно поддерживает утверждение, рядом с которым он указан. ALCE и ручной аудит оценивают этот аспект отдельно от качества конечного ответа. Ссылка, содержащая лишь похожие ключевые слова, не обязательно устанавливает причинный или количественный вывод.

Один и тот же документ может содержать и подтверждающий, и опровергающий фрагмент; нужен внимательный разбор контекста. Автоматическая метрика не заменяет чтение неоднозначной страницы.

Следует ли заявленный вывод из дизайна и результатов работы? Цитирование превращается в доказательство только при ясном соответствии между областью исследования и силой формулировки. Проверка не заканчивается совпадением ключевых слов: документ может отрицать то, для чего его цитируют. Контекст фразы определяет действительную поддержку.

ALCE и длинный ответ

Ответ с цитатами соединяет поиск документов и написание связного текста. Неудача возможна на любой из этих стадий: нужный документ не найден, найденный не прочитан, цитата назначена неверной фразе или содержательный ответ обрывается слишком рано. Измерение одной только беглости языка не выявит эти случаи. Равным образом верные ссылки на второстепенные факты не компенсируют отсутствие ответа на вопрос. Исследование систем цитирования важно тем, что разделяет стороны качества, обычно скрытые за общей оценкой «хорошо написано». Его тестовые задачи при этом не охватывают все научные жанры.

ALCE предложил набор задач и автоматические показатели для текста с цитатами, оценивая качество ответа и его атрибуцию. Авторы сравнивали разные способы работы с документами и обнаружили трудность одновременного получения информативности и правильной поддержки.

Метрики опираются на наборы вопросов, документы и модель оценки; они не утверждают, что любая сгенерированная ссылка истинна. Результаты исторически привязаны к проверенным системам.

Как совместить полноту объяснения с точностью каждой ссылки? Это исследовательская задача, а не свойство, возникающее от добавления сносок автоматически. Поскольку поиск и ответ оцениваются вместе, хороший итоговый показатель не изолирует улучшение одной стадии. Для причинного вывода нужны более узкие сравнения.

Доказательство и цитата

Ручной аудит поисковиков

Человеческий аудит поискового ответа возможен потому, что читатель может открыть страницу и сравнить её с написанным. Но такая работа трудоёмка, особенно если в одной фразе сразу несколько тезисов. Оценка полноты и точности поддержки даёт разные представления о сбое: неподкреплённое предложение и ошибочная ссылка не эквивалентны. Реальный поисковик также меняет выдачу со временем, поэтому результат определён временем проверки и набором вопросов. Сильная сторона аудита - конкретное чтение соответствия; его граница - выбранная выборка систем и запросов.

Liі и коллеги проверяли ответы четырёх тогдашних генеративных поисковых сервисов на вопросах разного происхождения. Люди оценивали, покрывают ли ссылки утверждения и подтверждают ли именно их. Исследование показало заметные проблемы обеих сторон проверяемости.

Бренды и версии сервисов позже менялись, поэтому конкретные доли нельзя выдавать за нынешнюю оценку продуктов. Выбор вопросов и человеческое суждение также ограничивают обобщение.

Сохранится ли вывод на новых доменах и обновлённых интерфейсах? Исторический аудит доказывает возможность сбоя, не вечное свойство каждого поискового инструмента. Когда поисковая выдача меняется, тот же вопрос может вызвать другие документы. Время аудита поэтому относится к доказательной записи, а не просто к календарю.

Доказательство и цитата

Атомарный факт

Длинный биографический или научный очерк редко бывает однородно верным либо неверным. Небольшие факты можно рассмотреть отдельно: должность, год, название, место, число участников. Это позволяет увидеть, что исправление одной детали не удостоверяет соседние. Но разбиение тоже требует интерпретации. Причинная фраза может иметь несколько предпосылок и один вывод; если разорвать её на части, исчезнет именно спорная связь. Поэтому атомарная фактическая оценка яснее бинарного ярлыка, сохраняя зависимость от определения единицы анализа.

FactScore предлагает разложить длинную генерацию на небольшие фактические единицы и оценить, сколько из них поддержано внешними знаниями. Это помогает обнаружить абзац, в котором рядом стоят точная дата и выдуманная должность.

Граница между атомами не всегда очевидна: причинная фраза может содержать условие и вывод. Автоматический поиск подтверждения зависит от доступной базы.

Как избежать потери смысла при дроблении сложного тезиса? Мера фактической точности полезна, когда единицы проверки прозрачны и доступен надёжный источник. Проверяемость отдельного атома зависит от доступной базы знаний. Отсутствие найденного подтверждения не всегда равно ложности, особенно для нового исследования.

Дополнительная трудность состоит в том, что предложение может соединять факт и оценочное слово. Источник подтверждает дату события, но не обязательно характеристику его значимости. При дроблении нужно сохранить различие наблюдения и интерпретации, иначе формально подтверждённый атом создаст ложную уверенность в общей фразе.

Источники: [A09](#)

Фактическая доля и покрытие

Процент подтверждённых фактов легко принять за процент полезности ответа. Однако текст из двух бесспорных утверждений способен получить хороший результат и не ответить на главный вопрос. Длинный текст с множеством правильных деталей может скрыть одну решающую ошибку. В обоих случаях одинаковый вес элементов не совпадает с их значимостью для читателя. Фактическая доля отвечает на вопрос о написанных единицах при выбранном источнике, а покрытие темы - на вопрос о недостающем материале. Это разные измерения, и одно не следует автоматически из другого.

Высокая доля подтверждённых атомов может быть достигнута кратким и осторожным текстом, который пропускает ключевой ответ. FActScore измеряет точность выделенных фактов, не полное качество ответа или его полезность. Это показывает необходимость различать истинность написанного и полноту темы.

Иной длинный текст может содержать много правильных второстепенных деталей, заслоняющих решающую ошибку. Равный вес атомов не всегда отражает важность для читателя.

Какие факты являются необходимыми для вывода? Оценка должна быть связана с вопросом, а не превращаться в безконтекстный процент. Именно пропущенное центральное обстоятельство может сделать краткий текст бесполезным при безупречной фактической точности оставшихся предложений.

Утверждения с числами

Число выглядит строгим, но без знаменателя и процедуры отбора его смысл неясен. Доля успешных патчей может относиться к одному агенту, определённым задачам и версии тестов. Если пересказать её как общую частоту ошибки программного ИИ, объект утверждения уже изменился. Аналогично показатель цитирования в нескольких поисковых системах не превращается в характеристику каждого ответа в сети. Точная запись числа означает не только десятичные знаки, но и указание популяции, момента измерения и характера исключённых случаев.

Число может быть верно для изученной выборки и неверно как универсальная частота. SWE-Bench+ сообщает проценты проблем в аудите конкретных успешных патчей, тогда как аудит поисковых систем относится к продуктам и запросам того периода. Цитата должна сохранять знаменатель.

Снятие оговорки о выборке создаёт кажущуюся точность при ошибочном обобщении. Даже точный URL не исправит расширенный смысл предложения.

Каковы дата, население и единица измерения данного процента? Сохранение этих условий делает статистику пригодной для честного сравнения. Стоит также отличать процентные пункты от относительного изменения. Смена этой формы в пересказе меняет впечатление о величине эффекта без изменения исходных данных.

Доказательство и цитата

Причинный вывод

Причинный вывод требует большего, чем соседство двух событий в статье. Если ответы с ссылками оказались качественнее, нельзя без соответствующего сравнения заключить, что именно добавление ссылок вызвало весь выигрыш: могли различаться поиск, генерация и отбор вопросов. Описательная корреляция полезна, но её логический статус другой. В кратком русском пересказе особенно легко потерять условное слово и написать «доказано». Для честной атрибуции следует сохранить именно степень уверенности, которая следует из дизайна первичной публикации.

Исследовательский текст нередко превращает корреляцию в причинное утверждение. Метрика citation precision спрашивает, достаточно ли документ поддерживает сформулированный тезис, а HELM напоминает различать сценарии и свойства оценки. Наличие опытного результата не даёт права распространять его на иную систему.

Даже экспериментальная статья может поддерживать только заданную интервенцию и метрику. Рецензионный обзор не заменяет первичные данные при спорной детализации.

Какая часть вывода непосредственно наблюдалась? Точность цитирования включает точность логического перехода от результата к предложению. Язык статистики ограничивает вывод: корреляция, сравнение при контроле и рандомизированное вмешательство поддерживают разные силы причинного утверждения.

При пересказе эксперимента изменение глагола бывает решающим: «связано», «предсказывает» и «вызывает» не являются равнозначными описаниями. Даже точная ссылка и число участников не восполняют неверную логическую силу вывода. Её следует брать из реально проведённого сравнения.

Источники: [A04](#) · [A07](#)

Отрицательные результаты

Отсутствие обнаруженного эффекта зависит от мощности исследования, метрики и изученного режима. Фраза «статья не нашла улучшения» не равна фразе «улучшения не бывает». В многоагентных задачах особенно важно, с чем сравнивали команду: одиночным агентом, несколькими независимыми попытками или иной организацией общения. Молчание публикации о конкретной настройке не является отрицательным результатом для неё. Читатель должен отличать измеренный ноль, неопределённую оценку и вопрос, который исследователи вообще не задавали.

Lost in the Middle обнаружил ухудшение на ряде длинноконтекстных задач, а исследование позиционного смещения судьи - зависимость оценки от порядка. Такие результаты легко пересказать слишком широко как «модели не читают середину» или «судьи всегда предвзяты».

Авторы изучали определённые системы и условия; контрпример на другой модели не отменяет исходное наблюдение. Дата и версия имеют значение.

Как выразить границу эффекта без потери его сути? Точная оговорка позволяет использовать отрицательный результат как знание, а не лозунг. Неопределённость иногда честнее категорического отрицания. Особенно когда работа не была рассчитана на обнаружение малого эффекта в новой подгруппе.

Недостаточная статистическая мощность и отсутствие подходящей контрольной группы создают разные ограничения. В первом случае не удаётся уверенно обнаружить эффект данного размера; во втором сложнее установить причинность. Общая фраза «ничего не показано» скрывает это различие.

Первичный текст и пересказ

Пересказ нужен, чтобы связать несколько исследований и перевести термины, но он добавляет собственный слой возможной ошибки. Автор может точно указать название работы и ошибиться в том, какая версия данных использована. Может сохранить число и опустить оговорку об ограниченном подмножестве. Проверка первичного текста важна именно потому, что поздний пересказ, даже добросовестный, уже является интерпретацией. Когда доступна только аннотация, лучше ограничиться её общим выводом, чем имитировать знание таблиц и методов, которые не были прочитаны.

Проверка научного утверждения выигрывает от чтения описания методов, таблиц и авторских ограничений, а не только заголовка или чужого пересказа. ALCE оценивает опору в предоставленном документе, аудит поиска обнаруживает слабость видимых цитат. Эти результаты мотивируют различать глубину чтения.

Даже полная статья может содержать ошибку, а аннотация иногда точно передаёт главный результат. Но уверенность в тонкой методической детали должна соответствовать тому, какую часть работы реально прочли.

Где именно в статье расположен поддерживающий результат? Честная отметка глубины чтения ограничивает силу утверждения и облегчает независимую проверку. Ссылка на первичную публикацию позволяет заметить, где начинается собственный синтез обзорщика. Эта граница должна оставаться читаемой даже в компактном тексте.

Доказательство и цитата

Исключение оговорки

Оговорка часто содержит условие, на котором держится истинность центрального результата. Фраза «в выбранных математических задачах» отделяет наблюдение от утверждения обо всех исследовательских заданиях. При сокращении текста такая часть кажется необязательной и исчезает первой. Тогда ссылка остаётся прежней, но написанное уже ей не соответствует. Не всякая оговорка одинаково существенна; важно выявлять те, которые меняют популяцию, критерий успеха, временной горизонт или причинную силу результата. Точность изложения выражается и в сохранении границ, а не только в сохранении положительного вывода.

Если источник говорит о конкретной версии бенчмарка, модели и наборе задач, удаление этих условий при пересказе меняет утверждение. Так аудит SWE-Bench+ нельзя свести к вечной доле ошибочных тестов. В ALCE подобная потеря контекста может выглядеть как формально существующая ссылка.

Ошибка часто не в вымышленной публикации, а в расширении её области. Автоматическая проверка может пропустить неявную подмену популяции.

Какие слова в предложении делают его шире источника? Выявление скрытого обобщения важно для исследовательской добросовестности. Иначе читатель получает не упрощённый вывод статьи, а новое, более сильное утверждение, за которое сама статья уже не отвечает.

Противоречащие работы

Две публикации могут сообщать разные результаты, потому что изучали разные условия, а не потому что одна ошибочна. Сначала надо установить совпадение задачи, метрики, времени и объекта оценки. Если один эксперимент касается полноты цитирования, другой - точности назначенных ссылок, их показатели могут двигаться в разные стороны. Взаимное цитирование работ не делает их непосредственно сопоставимыми. Подлинное противоречие возникает только тогда, когда утверждения несовместимы относительно одной и той же постановки. Это требование защищает литературу от драматизации и позволяет точнее назвать остающийся эмпирический вопрос.

Источники могут расходиться потому, что оценивают разные версии, популяции или метрики, а иногда потому, что один результат не воспроизвёлся. Позиционное смещение автоматических судей показывает, что даже сравнение работ может зависеть от формы подачи.

Перечисление двух URL не разрешает конфликт. Требуется смотреть условия, определения и качество проверки; при недостатке данных сохранять неопределённость.

Какие наблюдения несовместимы при одинаковых условиях? Различение настоящего противоречия и несопоставимости предотвращает ложный консенсус. Сначала стоит сравнить определения ключевых слов. Одинаковое «качество» может означать точность ответа, поддержку цитат или человеческое предпочтение.

Поиск не равен чтению

Результат поиска состоит из заголовка, отрывка и адреса; полный документ может содержать исключение, таблицу с другой подвыборкой или последующее исправление. Поисковый отрывок подтверждает наличие релевантной страницы, но обычно не достаточен для подробного вывода о методе. Даже открытая страница с аннотацией не означает, что прочитаны приложения. Глубина чтения является свойством конкретной работы с источником, а не знаком престижа сайта. Отмечая её, обзор делает видимым, какие предложения опираются на узкий доступный фрагмент, а какие на проверенный раздел исследования.

Система может найти релевантный документ, но не использовать его важный фрагмент в итоговом ответе. Lost in the Middle экспериментально показал зависимость извлечения от позиции, а ALCE отдельно оценивает опору в цитируемом материале. Успех поиска и успех синтеза являются разными событиями.

Тест позиции в контексте не полностью воспроизводит работу исследователя с множеством файлов. Но он опровергает наивное предположение, что доступность текста гарантирует учёт каждой строки.

Какая часть найденного материала повлияла на вывод? Трасса доступа и конечная атрибуция помогают различить пропуск и неверное толкование. Указывать аннотацию как аннотацию - содержательная честность. Она оставляет читателю возможность позднее углубить проверку без ложной уверенности.

Ложь, заимствованная из корпуса

Ошибочная информация может происходить не только от фантазии модели, но и от устойчивого повторения человеческих заблуждений. Вопросы, специально построенные на таких мифах, обнаруживают подражание распространённому ложному ответу. При оценке цитирования это создаёт особую ловушку: найти сайт, где повторена популярная ошибка, ещё не значит подтвердить её первичным исследованием. Следует различать свидетельство о том, что люди что-то говорят, и свидетельство о том, что сказанное верно. Эти цели требуют разных источников.

TruthfulQA проверяет ситуации, где популярный человеческий ответ на вопрос может быть ложным. Модель может уверенно повторить распространённую ошибку, не сочинив новой. Это иной источник ненадёжности, чем неверное извлечение из конкретного документа.

Бенчмарк специально сконструирован под такие ловушки и не измеряет все виды научных ошибок. Верность на нём может соседствовать с проблемами цитирования.

Откуда происходит кажущееся очевидным утверждение? Проверка первичного доказательства полезна даже когда ответ звучит знакомо. В таком случае цитата на страницу с мифом подтверждает лишь существование мифа. Истинность утверждения остаётся предметом отдельного свидетельства.

Такое подражание человеческим текстам напоминает, что внешнее подтверждение тоже требует оценки качества самого источника. Множество страниц может повторять один ошибочный слух; арифметическая многочисленность ссылок не образует независимую проверку.

Доказательство и цитата

Судья поддержки

Оценщик, решающий, поддерживает ли документ предложение, сам является частью измерительной цепи. Он способен пропустить тонкое изменение модальности, неверно соотнести два объекта или зависеть от порядка предъявления вариантов. Автоматическая оценка позволяет масштабировать сравнение, но её ошибки не исчезают от того, что она возвращает численный балл. Человеческая оценка тоже не безусловна: эксперты могут расходиться при сложной атрибуции. Сильное заключение требует знать, как в конкретном исследовании устанавливался эталон и на каких случаях проверялся судья.

Автоматический оценщик способен сравнивать ответы и документы, однако собственные ошибки и смещение положения влияют на вердикт. Исследования атрибуции и позиционного смещения исследуют разные стороны этой проблемы. Использование судьи не делает полученную оценку независимой истиной.

Человеческая проверка тоже имеет ограничения времени и согласованности, поэтому противопоставление человека и модели слишком грубо. Сила заключения зависит от качества эталона и проверенных сбоек судьи.

Насколько оценка воспроизводится при изменении порядка и эксперта? Обнародованные случаи расхождения дают более полную картину, чем один средний балл. Смена порядка двух ответов проверяет одну чувствительность судьи, но не все ошибки атрибуции. Следует избегать и преувеличения, и игнорирования этого наблюдения.

Перенос между языками

Перевод не просто заменяет слова; он переносит границы вывода между языками. Английское «may» можно неосторожно передать как «вызывает», а «in our sample» вовсе опустить. Тогда правильно указанная ссылка перестаёт поддерживать русское предложение. В обратную сторону русскоязычная оговорка может быть непрозрачна англоязычному автоматическому судье. Наличие успешных метрик на англоязычном корпусе не измеряет эту проблему напрямую. Поэтому точность перевода источника относится к содержанию атрибуции, а не к внешнему оформлению библиографии.

Оценки цитирования часто построены на англоязычных вопросах и корпусах. Перенос на русскоязычный ответ требует сохранить соответствие смысла между пересказом и оригиналом. Перевод может незаметно усилить модальность: «может» превратиться в «доказано».

Источниковая ссылка остаётся правильной строкой URL, но уже не подтверждает усиленное русское предложение. Автоматические англоязычные показатели не дают прямой гарантии качеству перевода.

Какие слова передают степень уверенности авторов? Верификация должна читать исходную формулировку и её перевод как отдельный логический шаг. Оговорки модальности могут быть короткими словами, однако именно они отделяют возможное объяснение от установленного эффекта.

Переводчик способен усилить не только вероятность, но и временной охват: «пока не наблюдалось» превращается в «не существует». Оба предложения внешне похожи, но второе требует гораздо более сильного свидетельства.

Воспроизводимый след

Открытые запросы и ответы позволяют понять, какую информацию увидела модель и какой текст она произвела. Но воспроизводимость зависит и от версии модели, состава корпуса, конфигурации поиска и времени обращения к изменяющейся странице. Опубликованная трасса ценна как свидетельство конкретного запуска, а не как гарантия идентичного вывода через годы. Она также не исправляет слабый тест: можно идеально воспроизвести неверно поставленную оценку. Разделение этих уровней помогает читать прозрачность как возможность проверки, а не как подтверждение правильности по умолчанию.

HELM опубликовал запросы и выходы для анализа, а ALCE - задачи и инструменты оценки атрибуции. Такой след позволяет другим исследователям увидеть, что именно было подано модели и получено в ответ. Без него итоговый процент трудно объяснить.

Открытость трассы сама по себе не исправляет слабый эталон или неверное толкование. Закрытые модели могут обновиться, так что идентичное повторение позже не гарантировано.

Можно ли локализовать ошибку в данных, ответе или судьбе? Доступный след облегчает ответ, сохраняя пределы воспроизводимости. Воспроизводимый след также помогает исправить описание собственного материала. Но он не превращает запись запуска в независимую репликацию результата.

Открытый стандарт доказательства

Сильный исследовательский текст позволяет читателю восстановить путь от конкретного утверждения к источнику и понять, какие возражения источник не снимает. Число URL само по себе этого не обеспечивает. Локальная точность ссылок, охват существенных предложений, истинность атомарных фактов и полнота ответа являются связанными, но разными свойствами. Публикации предлагают метрики для частей этой картины; единой автоматической отметки для всех её сторон пока нет. Поэтому итоговая оценка должна сохранять видимыми предмет измерения, предел корпуса и возможные ошибки оценщика.

Исследования атрибуции и атомарной точности показывают, что доказательная сила длинного ответа составна. Нужны проверяемые утверждения, доступные первичные документы, точное соответствие и правильные ограничения вывода. Публикации пока не дают единственной автоматической метрики для всего этого.

Слишком жёсткая формальная проверка может пропустить содержательное объяснение, а слишком мягкая принять красивый текст с пустыми ссылками. Каждый показатель измеряет только определённую часть качества.

Какие элементы доступны независимому читателю без доверия к автору ответа? Именно возможность проследить утверждение к соответствующему источнику делает исследовательский текст проверяемым. Сопоставление частей позволяет честно сказать «этот факт подтверждён, связь пока нет». Такое предложение информативнее красивого общего балла.

Границы открытого вывода

Итоговый текст способен содержать хорошо подтверждённые предложения и спорную связку между ними. Например, источник поддерживает два отдельных наблюдения, но не общий причинный рассказ. Ссылка возле каждого фрагмента ещё не решает вопрос о связи. Атрибуция касается не только фактов, но и степени их обобщения. Опубликованные исследования предложили инструменты для частичной оценки; их результаты не создают автоматического удостоверения всех жанров научного объяснения. Потому предел доступных свидетельств является частью содержательного вывода, а не дефектом оформления.

Оценки цитат и атомарной точности показывают отдельные стороны длинного ответа; одна метрика не подтверждает весь научный вывод.

Результаты зависят от языка, корпуса документов и эталона.

Что остаётся за проверенной частью? Читателю важно видеть пробелы, а не только подтверждённые фразы. Оставшаяся неопределённость не мешает сообщить установленные факты. Она указывает, какое именно следующее утверждение пока не поддержано прочитанными работами.

Раздельная атрибуция позволяет исправить одну ошибку, не перечёркивая добросовестно подтверждённые части обзора. Такая локальная корректируемость важнее видимости безупречного, но непрозрачного заключения. Особенно полезно различать честное признание пробела и ошибочную уверенность, скрывающую его за множеством настоящих, но нерелевантных ссылок.